

Homework 13

Question 1.

与上一次作业不同的是 E 的更新使用上一轮的 Z 而非新更新的 Z ，以及一些参数的变化（如 η_D ）。

引入拉格朗日乘子 $Y_1 \in \mathbb{R}^{m \times n}$, $Y_2 \in \mathbb{R}^{n \times 1}$ ，增广拉格朗日函数为：

$$\begin{aligned} \mathcal{L}(Z, E, Y_1, Y_2) = & \|Z\|_* + \lambda \|E\|_{2,1} + \langle Y_1, D - DZ - E \rangle + \frac{\beta}{2} \|D - DZ - E\|_F^2 \\ & + \langle Y_2, Z^\top \mathbf{1} - \mathbf{1} \rangle + \frac{\beta}{2} \|Z^\top \mathbf{1} - \mathbf{1}\|_2^2 \end{aligned}$$

更新 Z . 我们线性化增广拉格朗日中关于 Z 的二次项，得到以下更新：

$$Z^{k+1} = \arg \min_Z \|Z\|_* + \frac{\beta_k}{2} \|Z - G^k\|_F^2$$

其中：

$$G^k = Z^k - \frac{1}{\eta_D} \left(D^\top (DZ^k + E^k - D) + \mathbf{1} (Z^{k\top} \mathbf{1} - \mathbf{1})^\top + \frac{1}{\beta_k} D^\top Y_1^k + \frac{1}{\beta_k} \mathbf{1} Y_2^{k\top} \right)$$

该子问题的解为奇异值软阈值：

$$Z^{k+1} = \text{SVT}_{1/\eta_D \beta_k}(G^k)$$

更新 E . 对 E 的更新为：

$$E^{k+1} = \arg \min_E \lambda \|E\|_{2,1} + \frac{\beta_k}{2} \left\| E - \left(D - DZ^{k+1} + \frac{1}{\beta_k} Y_1^k \right) \right\|_F^2$$

这是 $\ell_{2,1}$ 范数的近端问题，解为对每列进行缩放：

$$E_{:,j}^{k+1} = \left[1 - \frac{1}{\beta_k \|R_{:,j}\|_2} \right]_+ R_{:,j}, \quad R = D - DZ^{k+1} + \frac{1}{\beta_k} Y_1^k$$

更新拉格朗日乘子.

$$Y_1^{k+1} = Y_1^k + \beta_k (D - DZ^{k+1} - E^{k+1})$$

$$Y_2^{k+1} = Y_2^k + \beta_k (Z^{k+1\top} \mathbf{1} - \mathbf{1})$$

自适应步长更新. 使用如下策略自适应更新 β_k ：

$$\beta_{k+1} = \min(\rho \beta_k, \beta_{\max})$$

$$\rho = \begin{cases} \rho_0, & \text{if } \beta_k \max(\sqrt{\eta_D} \|\mathbf{x}_{k+1} - \mathbf{x}_k\|, \|\mathbf{y}_{k+1} - \mathbf{y}_k\|) / \|\mathbf{c}\| < \varepsilon_2 \\ 1, & \text{otherwise} \end{cases}$$

收敛条件.

$$\frac{\|DZ^k + E^k - D\|}{\|D\|} \leq \epsilon_1, \text{ or } \max \left(\frac{\|D^k - D^{k-1}\|}{\|D\|}, \frac{\|E^k - E^{k-1}\|}{\|D\|} \right) < \epsilon_2$$

数据实验. 参数选取上, $\epsilon_1 = 10^{-6}$, $\epsilon_2 = 10^{-5}$, $\beta_0 = \min(n, m)\epsilon_2 = 200\epsilon_2$, $\beta_{\max} = 10^{10}$, $\rho_0 = 1.9$, $\eta_D = 2.02\sigma_{\max}^2(D)$, $\lambda = 0.1$, 最大迭代次数 5000 次。最终实验结果如图1




图 1. LADMPSAP 收敛行为

Question 2.

$$\min_{\bar{\mathbf{w}} \in \mathbb{R}^d} \frac{1}{s} \sum_{i=1}^s \log(1 + \exp(-y_i \bar{\mathbf{w}}^\top \bar{\mathbf{x}}_i))$$

其中 $\bar{\mathbf{x}}_i \in \mathbb{R}^d$, $y_i \in \{-1, +1\}$ 。

梯度的 Lipschitz 常数. 逻辑损失的梯度

$$\nabla f(\bar{\mathbf{w}}) = -\frac{1}{s} \sum_{i=1}^s y_i \bar{\mathbf{x}}_i \cdot \sigma(-y_i \bar{\mathbf{w}}^\top \bar{\mathbf{x}}_i)$$

其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ 。

Hessian

$$\nabla^2 f(\bar{\mathbf{w}}) = \frac{1}{s} \sum_{i=1}^s \sigma(y_i \bar{\mathbf{w}}^\top \bar{\mathbf{x}}_i) (1 - \sigma(y_i \bar{\mathbf{w}}^\top \bar{\mathbf{x}}_i)) \bar{\mathbf{x}}_i \bar{\mathbf{x}}_i^\top$$

由于对任意实数 z 有

$$\sigma(z)(1 - \sigma(z)) \leq \frac{1}{4}$$

可得 Hessian 的谱范数（最大特征值）满足：

$$\|\nabla^2 f(\bar{\mathbf{w}})\| \leq \frac{1}{4s} \sum_{i=1}^s \|\bar{\mathbf{x}}_i\|^2 = \frac{1}{4s} \|\bar{\mathbf{X}}\|_F^2$$

因此梯度 Lipschitz 常数满足：

$$L_{\bar{\mathbf{w}}} \leq \frac{1}{4s} \|\bar{\mathbf{X}}\|_F^2$$

pLADMPSAP 推导. 引入局部变量 $\bar{\mathbf{w}}_i$ 和约束

$$\bar{\mathbf{w}}_i = \bar{\mathbf{w}}, \quad \forall i = 1, \dots, s$$

优化问题变为

$$\min_{\{\bar{\mathbf{w}}_i\}, \bar{\mathbf{w}}} \frac{1}{s} \sum_{i=1}^s \log(1 + \exp(-y_i \bar{\mathbf{w}}_i^\top \bar{\mathbf{x}}_i)) \quad \text{s.t. } \bar{\mathbf{w}}_i = \bar{\mathbf{w}}, 1 \leq i \leq s$$

构造增广拉格朗日

$$\mathcal{L} = \frac{1}{s} \sum_{i=1}^s \log(1 + \exp(-y_i \bar{\mathbf{w}}_i^\top \bar{\mathbf{x}}_i)) + \sum_{i=1}^s \langle \alpha_i, \bar{\mathbf{w}}_i - \bar{\mathbf{w}} \rangle + \frac{\rho}{2} \sum_{i=1}^s \|\bar{\mathbf{w}}_i - \bar{\mathbf{w}}\|^2$$

在第 k 次迭代中, 执行以下操作:

1) 更新局部变量 $\bar{\mathbf{w}}_i^{k+1}$, 使用梯度下降:

$$\bar{\mathbf{w}}_i^{k+1} = \arg \min \left\{ \frac{1}{s} \log(1 + \exp(-y_i \bar{\mathbf{w}}_i^\top \bar{\mathbf{x}}_i)) + \langle \alpha_i^k, \bar{\mathbf{w}}_i - \bar{\mathbf{w}}^k \rangle + \frac{\rho}{2} \|\bar{\mathbf{w}}_i - \bar{\mathbf{w}}^k\|^2 \right\}$$

2) 更新全局变量 $\bar{\mathbf{w}}$:

$$\bar{\mathbf{w}}^{k+1} = \frac{1}{s} \sum_{i=1}^s \left(\bar{\mathbf{w}}_i^{k+1} + \frac{1}{\rho} \alpha_i^k \right)$$

3) 更新拉格朗日乘子:

$$\alpha_i^{k+1} = \alpha_i^k + \rho(\bar{\mathbf{w}}_i^{k+1} - \bar{\mathbf{w}}^{k+1})$$

数据实验. 选取 $s = 30, d = 20$, 随机生成 $X \in \mathbb{R}^{s \times d}$ 和 $w \in \mathbb{R}^d$, $y = \text{sign}(Xw + \sigma\varepsilon)$, $\sigma = 0.1, \varepsilon \sim N(0, 1)$ 。最大迭代次数 10000 次。梯度下降方法学习率 0.1, 停止标准 $\|\nabla f(x)\| \leq 10^{-6}$ 。pLADPSAP 方法 $\rho = 1.0$, 停止标准 $\|w_i - w\| \leq 10^{-6}$ 。实验结果如图2, GD 收敛更快。

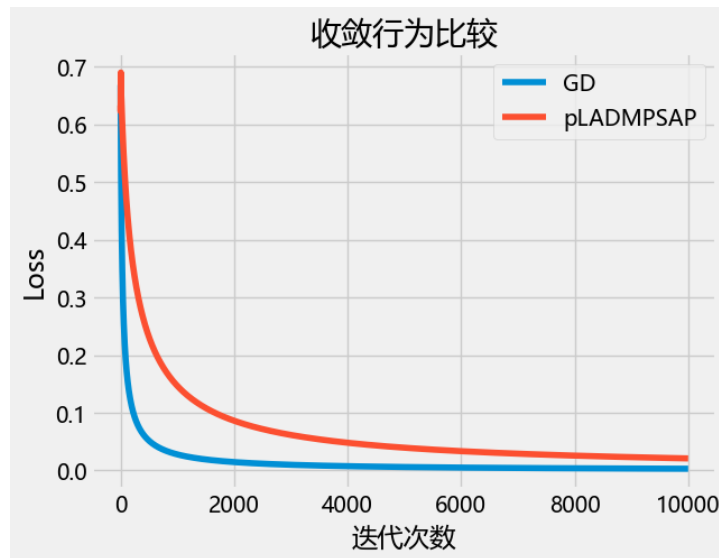


图 2. 收敛行为比较

Question 3.

固定 D, 更新 X. 固定字典 \mathbf{D} 后, \mathbf{X} 的优化问题变为

$$\min_{\mathbf{X}} \frac{1}{2} \|\mathbf{Y} - \mathbf{DX}\|_F^2 + \lambda \|\mathbf{X}\|_1$$

可以将其拆解为 n 个独立的 Lasso 问题

$$\min_{\mathbf{x}_i} \frac{1}{2} \|\mathbf{y}_i - \mathbf{D}\mathbf{x}_i\|_2^2 + \lambda \|\mathbf{x}_i\|_1, \quad \forall i = 1, \dots, n$$

固定 \mathbf{X} , 更新 \mathbf{D} . 此时优化目标变为

$$\min_{\mathbf{D}} \quad \frac{1}{2} \|\mathbf{Y} - \mathbf{D}\mathbf{X}\|_F^2 \quad \text{s.t.} \quad \|\mathbf{d}_i\|_2 = 1, \quad \forall i.$$

忽略约束条件时, 有闭式解

$$\mathbf{D} = \mathbf{Y}\mathbf{X}^\top (\mathbf{X}\mathbf{X}^\top)^{-1}.$$

为防止矩阵奇异, 引入正则项, 得

$$\mathbf{D} = \mathbf{Y}\mathbf{X}^\top (\mathbf{X}\mathbf{X}^\top + \epsilon \mathbf{I})^{-1}.$$

为了满足约束 $\|\mathbf{d}_i\|_2 = 1$, 对每一列归一化

$$\mathbf{d}_i \leftarrow \frac{\mathbf{d}_i}{\|\mathbf{d}_i\|_2}, \quad \forall i.$$

实验参数选取. 参数选取上, $\lambda = 0.01$, 最大迭代次数 500 次, 为防止矩阵奇异引入的正则项系数 $\epsilon = 10^{-3}$, Lasso 问题使用 `sklearn.linear_model.Lasso` 求解, 最大迭代次数 1000 次。实验结果如图3。

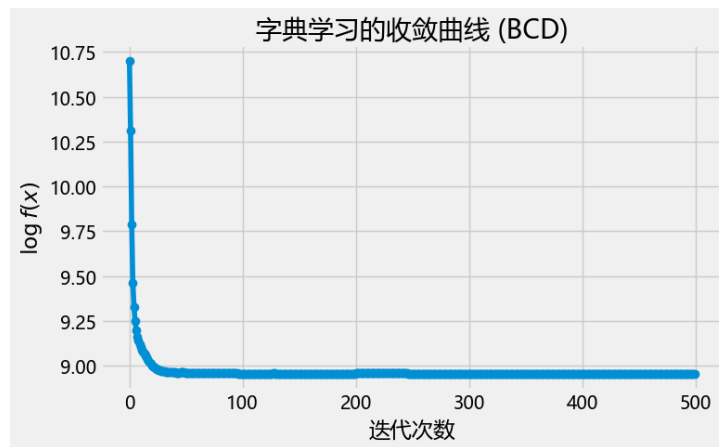


图 3. 收敛行为

Question 4.

更新 \mathbf{A}

固定 \mathbf{U} 和 \mathbf{V} , 我们更新 \mathbf{A} 的问题为:

$$\min_{\mathbf{A}} \quad \frac{1}{2} \|\mathbf{U}\mathbf{V}^\top - \mathbf{A}\|_F^2, \quad \text{s.t.} \quad \mathcal{P}_\Omega(\mathbf{A}) = \mathcal{P}_\Omega(\mathbf{D}).$$

该问题的解析解为:

$$\mathbf{A} = \mathcal{P}_\Omega(\mathbf{D}) + \mathcal{P}_{\Omega^c}(\mathbf{U}\mathbf{V}^\top),$$

即在观测位置保留原始数据, 其余位置用当前的低秩估计补全。

更新 \mathbf{U}

固定 \mathbf{A} 和 \mathbf{V} , 我们更新 \mathbf{U} 的问题为:

$$\min_{\mathbf{U}} \quad \frac{1}{2} \|\mathbf{U}\mathbf{V}^\top - \mathbf{A}\|_F^2.$$

该问题的解析解为:

$$\mathbf{U} = \mathbf{A}\mathbf{V}(\mathbf{V}^\top \mathbf{V})^{-1}.$$

更新 \mathbf{V}

固定 \mathbf{A} 和 \mathbf{U} , 我们更新 \mathbf{V} 的问题为:

$$\min_{\mathbf{V}} \quad \frac{1}{2} \|\mathbf{U}\mathbf{V}^\top - \mathbf{A}\|_F^2.$$

该问题的解析解为：

$$\mathbf{V} = \mathbf{A}^\top \mathbf{U} (\mathbf{U}^\top \mathbf{U})^{-1}.$$

正交化步骤

为提升算法的数值稳定性，我们可在每轮迭代中对 \mathbf{U} 或 \mathbf{V} 进行 QR 正交化处理。例如：

$$\mathbf{U} \leftarrow \mathbf{Q}, \quad \text{其中 } \mathbf{QR} = \text{QR 分解}(\mathbf{U}).$$

实验设置

根据题目要求随机生成相应的矩阵，数据实验结果如图4。能够看出，在经历相当多的迭代次数后，更新 \mathbf{U} 后正交化的策略收敛。

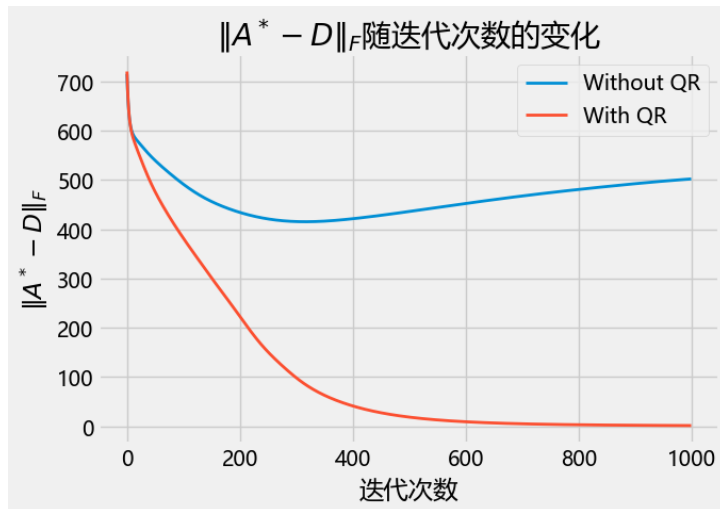


图 4. $\|A^* - D\|_F$ 随迭代次数的变化

Question 5.

每轮迭代分为两步：

- Step 1: 更新 \mathbf{y}_i

固定 $\mathbf{x}^{(k)}$ ，每个 \mathbf{y}_i 独立优化

$$\mathbf{y}_i^{(k+1)} = \text{Proj}_{\mathcal{X}_i}(\mathbf{x}^{(k)})$$

- Step 2: 更新 \mathbf{x}

固定所有 $\mathbf{y}_i^{(k+1)}$ ，则有闭式解：

$$\mathbf{x}^{(k+1)} = \frac{1}{m} \sum_{i=1}^m \mathbf{y}_i^{(k+1)}$$

5.1. 收敛性分析

若所有集合 \mathcal{X}_i 是非空闭凸集，且它们的交集非空，即

$$\bigcap_{i=1}^m \mathcal{X}_i \neq \emptyset$$

则上述算法生成的序列 $\mathbf{x}^{(k)}$ 将收敛到该交集中的一点。该点即为原始问题的最优解。

数据实验 $m = 5$ 时，随机生成 5 个圆心在 $[-3, 3]^2$ ，半径为 3 的二维圆盘，生成若干次直至所有圆盘的交集不为空。初始点 $\mathbf{x}^{(0)}$ 从 $[-20, 20]^2$ 中产生，生成若干次直至该点不在所有圆盘的交集中，作为初始位置。运行 100 次迭代，记录收敛过程如图5。

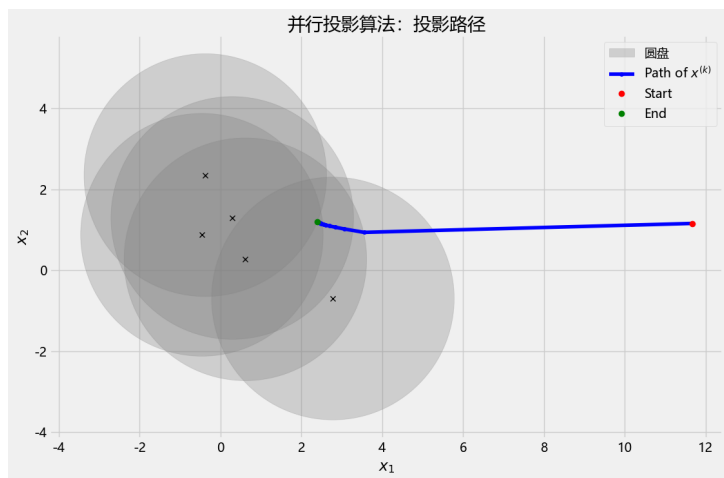


图 5. 投影路径